

Rapport technique : EduTrack Analytics

Projet Spé DATA, Maroc Ynov Campus.

Démonstration vidéo : https://drive.google.com/file/d/1yJYg1_yLmzMC4qEJgLP1PmkmyHiqSXLS/view?usp=drive_link

1. Contexte et problématique

Un établissement génère beaucoup de données académiques (notes, absences, retards, modules, classes) qui servent rarement à autre chose qu'au calcul des moyennes. EduTrack Analytics part de ces données pour produire des indicateurs et des alertes utilisables par l'administration et les formateurs.

La question de départ : comment repérer assez tôt les étudiants en difficulté et donner aux responsables pédagogiques une vue claire de la performance, en se basant uniquement sur les données académiques disponibles ?

La plateforme couvre toute la chaîne : import, nettoyage, analyse, visualisation, détection du risque et génération de rapports.

2. Choix techniques

Couche	Technologie	Justification
Backend	FastAPI (Python)	Asynchrone, documentation OpenAPI automatique, s'intègre directement avec pandas
Données	pandas, NumPy	Manipulation des tableaux et calculs statistiques
Base de données	PostgreSQL	Base relationnelle, adaptée aux clés étrangères et à l'intégrité
ORM / migrations	SQLAlchemy, Alembic	Modèle déclaratif et migrations versionnées
Frontend	Next.js (React) + Tailwind	Tableau de bord réactif, composants de graphiques riches
Visualisation	Recharts, Matplotlib	Graphiques interactifs côté web, graphiques statiques pour le PDF
Authentification	JWT	Authentification sans état, simple à intégrer
Rapports	Jinja2 + WeasyPrint	Génération HTML puis conversion PDF
Déploiement	Docker Compose	Démarrage reproductible en une commande

Python est le langage principal imposé par le cahier des charges. Il a aussi l'avantage de réunir l'API et le traitement des données dans le même écosystème, donc pas besoin de jongler entre plusieurs langages.

3. Architecture

Le code est découpé par responsabilité, comme demandé dans le cahier des charges. Les données suivent toujours le même chemin : un fichier importé passe par le pipeline, est stocké dans PostgreSQL, lu par la couche d'analyse, exposé par l'API, puis affiché dans le frontend.

Couche	Contenu
Pipeline	reader, cleaner, validator, loader (orchestrés par <code>runner</code> , détection du type via <code>schema_spec</code>)

Couche	Contenu
Base PostgreSQL	students, classes, modules, grades, absences, imports, alerts, settings
Analyse	statistiques, corrélations, anomalies, score de risque, segmentation
API (FastAPI)	/auth, /imports, /analytics, /students, /classes, /modules, /alerts, /reports
Frontend (Next.js)	tableau de bord, visualisations, fiches étudiants, rapports

Côté backend, chaque module a un rôle précis : `core` (configuration, base, sécurité), `models` (schéma relationnel), `pipeline` (traitement des données), `analytics` (calculs), `reports` (génération de rapports) et `api/routers` (endpoints).

4. Schéma de la base de données

Le modèle relationnel comprend neuf tables. Les relations sont protégées par des clés étrangères pour garantir la cohérence entre étudiants, classes, modules et résultats.

- **users** : comptes d'accès (email, mot de passe haché, rôle)
- **classes** : groupes ou promotions
- **modules** : matières (code, nom, coefficient)
- **students** : étudiants, rattachés à une classe
- **grades** : notes, liées à un étudiant et un module
- **absences** : absences et retards, liés à un étudiant
- **imports** : historique des imports (fichier, lignes traitées, statut)
- **alerts** : alertes générées par étudiant
- **settings** : seuils pédagogiques configurables

Le script SQL complet est disponible dans `backend/schema.sql` et les migrations dans `backend/alembic/`.

5. Pipeline de traitement des données

Le pipeline applique six étapes successives, orchestrées par `app/pipeline/runner.py` :

1. **Lecture** (`reader.py`) : lecture du CSV ou de l'Excel dans un DataFrame pandas.
2. **Normalisation** (`cleaner.normalize_columns`) : mise en forme des en-têtes et correspondance des alias français et anglais vers des noms canoniques. Le type de fichier (notes, absences...) est ensuite détecté automatiquement à partir des colonnes (`schema_spec.detect_type`).
3. **Validation** (`validator.py`) : vérification des colonnes obligatoires, des valeurs manquantes et des formats. Les erreurs bloquantes interrompent l'import.
4. **Nettoyage** (`cleaner.clean`) : suppression des doublons, conversion des types, traitement des valeurs nulles, suppression des notes hors de l'intervalle 0 à 20.
5. **Chargement** (`loader.py`) : résolution ou création des classes et modules, insertion des entités dans PostgreSQL au sein d'une transaction.
6. **Journalisation** : chaque import est enregistré dans la table `imports` avec le nombre de lignes traitées, rejetées et le statut.

Les fichiers de test dans `data/samples/edge_cases` contiennent volontairement des problèmes (doublons, valeurs manquantes, notes hors borne, date invalide, colonne absente) pour vérifier que le nettoyage et la validation réagissent bien.

6. Analyse exploratoire (EDA)

L'analyse exploratoire est détaillée dans le notebook `notebook/EDA.ipynb` (exécuté, sorties incluses). Principaux résultats sur le jeu de données synthétique :

- **Distribution des notes** : répartition centrée autour du seuil de validation, avec une part notable d'étudiants sous la moyenne.
- **Statistiques descriptives** : moyenne, médiane, écart-type et quartiles calculés par module et par classe, faisant ressortir les modules les plus difficiles et les écarts entre groupes.
- **Corrélations** : corrélation négative entre les heures d'absence et la moyenne ($\approx -0,52$), confirmant le lien entre assiduité et performance.
- **Anomalies** : détection des notes inhabituelles par z-score (19 notes au seuil $|z| \geq 2,5$) et des absences excessives par la méthode de Tukey/IQR (7 étudiants au-dessus du seuil).

7. Tableau de bord et visualisations

Le tableau de bord présente au moins cinq visualisations interactives :

1. Histogramme de **distribution des notes**.
2. **Comparaison des classes** (moyenne par classe).
3. **Réussite / échec par module**.
4. **Heatmap de corrélation** (absences, retards, notes).
5. **Évolution par période** sur la fiche étudiant.
6. **Répartition par segment** (camembert des niveaux : excellent, stable, moyen, fragile, à risque).






Tableau de bord : KPIs globaux, distribution des notes, moyenne par classe, corrélations et répartition par segment.





Fiche individuelle : moyenne, classement, évolution par période et recommandations.

L'interface est entièrement bilingue (français / anglais) : un sélecteur de langue mémorise le choix de l'utilisateur et tous les libellés, tableaux, graphiques, segments, alertes et recommandations sont traduits. Des info-bulles explicatives accompagnent les indicateurs et les seuils (score de risque, taux d'absence, z-score, IQR) pour rendre la lecture intuitive.

8. Détection du risque et alertes

La détection des étudiants à risque repose sur des règles statistiques combinant trois signaux, pondérés dans un score de risque de 0 à 100 (`app/analytics/risk.py`) :

- moyenne faible par rapport au seuil de validation ;
- taux d'absence élevé par rapport à un volume horaire de référence ;
- baisse de performance entre la première et la dernière période (périodes ordonnées chronologiquement, ou par ordre naturel à défaut de date).

Le score détermine un segment : *excellent*, *stable*, *moyen*, *fragile*, à *risque*. Cette segmentation repose sur des règles statistiques explicites, et non sur un clustering non supervisé (K-Means), qui reste une piste d'extension (Bonus B). Des alertes typées sont générées (moyenne faible, absences élevées, baisse de performance) avec un niveau de gravité. L'API renvoie des codes d'alerte et de recommandation accompagnés des valeurs mesurées ; l'interface les restitue en français ou en anglais, et le rapport PDF/HTML les rend en français.

Alertes pédagogiques

Détection automatique des étudiants à risque

Générer les alertes




Alertes actives

Type	Gravité	Message	Étudiant
Absences élevées	Élevée	Taux d'absence élevé (15.0 %).	#103
Moyenne faible	Élevée	Moyenne faible (5.1) sous le seuil de 10.	#103
Absences élevées	Élevée	Taux d'absence élevé (31.0 %).	#121
Moyenne faible	Élevée	Moyenne faible (5.33) sous le seuil de 10.	#121
Baisse de performance	Élevée	Baisse de performance de 3.98 points entre les périodes.	#121
Absences élevées	Élevée	Taux d'absence élevé (22.5 %).	#122
Moyenne faible	Élevée	Moyenne faible (5.16) sous le seuil de 10.	#122
Baisse de performance	Élevée	Baisse de performance de 3.99 points entre les périodes.	#122
Absences élevées	Élevée	Taux d'absence élevé (28.0 %).	#123
Moyenne faible	Élevée	Moyenne faible (5.61) sous le seuil de 10.	#123
Baisse de performance	Élevée	Baisse de performance de 4.47 points entre les périodes.	#123
Absences élevées	Élevée	Taux d'absence élevé (27.0 %).	#124
Moyenne faible	Élevée	Moyenne faible (5.4) sous le seuil de 10.	#124
Baisse de performance	Élevée	Baisse de performance de 3.85 points entre les périodes.	#124
Absences élevées	Élevée	Taux d'absence élevé (23.0 %).	#125
Moyenne faible	Élevée	Moyenne faible (5.75) sous le seuil de 10.	#125
Baisse de performance	Élevée	Baisse de performance de 3.84 points entre les périodes.	#125
Moyenne faible	Moyenne	Moyenne faible (6.73) sous le seuil de 10.	#66
Moyenne faible	Moyenne	Moyenne faible (8.1) sous le seuil de 10.	#98
Baisse de performance	Moyenne	Baisse de performance de 3.14 points entre les périodes.	#98
Moyenne faible	Moyenne	Moyenne faible (4.91) sous le seuil de 10.	#120
Moyenne faible	Faible	Moyenne faible (8.99) sous le seuil de 10.	#1
Moyenne faible	Faible	Moyenne faible (6.93) sous le seuil de 10.	#3
Moyenne faible	Faible	Moyenne faible (9.51) sous le seuil de 10.	#5
Baisse de performance	Faible	Baisse de performance de 3.5 points entre les périodes.	#7
Moyenne faible	Faible	Moyenne faible (9.05) sous le seuil de 10.	#8
Moyenne faible	Faible	Moyenne faible (9.83) sous le seuil de 10.	#9
Moyenne faible	Faible	Moyenne faible (9.56) sous le seuil de 10.	#12
Baisse de performance	Faible	Baisse de performance de 3.45 points entre les périodes.	#12
Moyenne faible	Faible	Moyenne faible (9.98) sous le seuil de 10.	#17
Moyenne faible	Faible	Moyenne faible (9.27) sous le seuil de 10.	#19
Moyenne faible	Faible	Moyenne faible (8.47) sous le seuil de 10.	#27
Moyenne faible	Faible	Moyenne faible (9.99) sous le seuil de 10.	#28
Baisse de performance	Faible	Baisse de performance de 4.46 points entre les périodes.	#30
Moyenne faible	Faible	Moyenne faible (9.65) sous le seuil de 10.	#34
Moyenne faible	Faible	Moyenne faible (9.55) sous le seuil de 10.	#36
Moyenne faible	Faible	Moyenne faible (9.44) sous le seuil de 10.	#40
Moyenne faible	Faible	Moyenne faible (9.64) sous le seuil de 10.	#41
Moyenne faible	Faible	Moyenne faible (7.74) sous le seuil de 10.	#48
Moyenne faible	Faible	Moyenne faible (9.09) sous le seuil de 10.	#49
Moyenne faible	Faible	Moyenne faible (9.16) sous le seuil de 10.	#54
Moyenne faible	Faible	Moyenne faible (5.92) sous le seuil de 10.	#55
Moyenne faible	Faible	Moyenne faible (8.25) sous le seuil de 10.	#57
Moyenne faible	Faible	Moyenne faible (9.91) sous le seuil de 10.	#60
Baisse de performance	Faible	Baisse de performance de 3.73 points entre les périodes.	#61
Moyenne faible	Faible	Moyenne faible (6.97) sous le seuil de 10.	#64
Moyenne faible	Faible	Moyenne faible (8.72) sous le seuil de 10.	#65
Moyenne faible	Faible	Moyenne faible (7.82) sous le seuil de 10.	#68
Baisse de performance	Faible	Baisse de performance de 4.55 points entre les périodes.	#69
Moyenne faible	Faible	Moyenne faible (9.5) sous le seuil de 10.	#71
Moyenne faible	Faible	Moyenne faible (9.73) sous le seuil de 10.	#76
Moyenne faible	Faible	Moyenne faible (8.38) sous le seuil de 10.	#81
Moyenne faible	Faible	Moyenne faible (8.99) sous le seuil de 10.	#87
Moyenne faible	Faible	Moyenne faible (7.5) sous le seuil de 10.	#88
Moyenne faible	Faible	Moyenne faible (8.1) sous le seuil de 10.	#95
Moyenne faible	Faible	Moyenne faible (9.93) sous le seuil de 10.	#100
Baisse de performance	Faible	Baisse de performance de 3.47 points entre les périodes.	#100

9. Bonus C : génération automatique de rapports

Le module `app/reports/generator.py` produit un rapport pédagogique à partir des données importées. Les graphiques sont générés avec Matplotlib et encodés dans le document, le rendu est assuré par un gabarit Jinja2, puis converti en PDF avec WeasyPrint. Le rapport contient les KPIs, la distribution des notes, la comparaison des classes, l'analyse par module, la segmentation et la liste des étudiants à risque avec recommandations. Il est téléchargeable depuis l'application.



Page de génération de rapports (PDF / HTML).

10. Import des données

EduTrack Analytics

Tableau de bord

Classes

Modules

Étudiants

Anomalies

Alertes

Imports

Rapports

FR

EN

Déconnexion

Import de données

Fichiers CSV ou Excel (étudiants, notes, absences)

Fichier

Choose File

No file chosen

Type ?

Détection automatique

Importer

Historique des imports

Date	Fichier	Type	Traitées	Rejetées	Statut
15/06/2026 12:36:38	absences.xlsx	absences	447	0	Succès
15/06/2026 12:36:38	notes.csv	grades	2000	0	Succès
15/06/2026 12:36:37	etudiants.csv	students	125	0	Succès

Import de fichiers CSV / Excel avec rapport de validation et historique des imports.

11. Tests et qualité

Le backend est couvert par des tests unitaires et d'intégration (`backend/tests/`) : normalisation et nettoyage des colonnes, validation, scoring du risque, et un test d'intégration complet de l'import. La commande `pytest` exécute l'ensemble de la suite.

12. Conclusion

Le projet répond aux demandes du cahier des charges : import et nettoyage des fichiers, base relationnelle, tableau de bord avec plusieurs visualisations, détection du risque à partir des données, segmentation des étudiants et génération de rapports (bonus C). Le découpage en modules laisse de la place pour aller plus loin, par exemple un modèle prédictif du risque d'échec ou un clustering K-Means.